机器学习工程师 · 求职 · 实习均可

Mustofa A. Ahmed

专注于让大模型在真实硬件上高效运行：大语言模型推理、投机解码，以及面向 GPU、FPGA 和 NPU 的模型部署。现为中国科学院大学 / 中国科学院高能物理研究所博士研究生。

hafizabc77@gmail.com · mustofa@ihep.ac.cn · +86 131 1517 9862
github.com/hafizabc77 · ORCiD 0009-0009-4363-9342 · 中国 · 北京

我的网站
hafizabc77.github.io

工作经历

算法研发实习生 · 中科紫东太初（北京）科技有限公司 2026.07 – 2026.10 · 北京

- 在 Qwen3.5-4B 上复现 DFlash 与 DSpark 投机解码，开发支持 DSpark 的 vLLM 推理运行时。
- 解决模型加载、混合注意力与 CUDA Graph 兼容性问题；在 RTX 4090 上基于 GSM8K、HumanEval 和 MT-Bench 完成基准测试。

科研人员 · 中国科学院高能物理研究所 计算中心 2023 至今 · 北京

- 面向 CEPC 与 CMS（CERN）粒子物理实验开展机器学习部署：基于 TensorRT 和 ONNX 部署 ParticleNet / ParT。
- 开发 AutoDeploy 及其部署知识图谱；训练 DFlash 草稿模型并开展 vLLM 推理服务研究。

网站开发工程师 · GeePower Energy Technology 2021 – 2022 · 扬州

- 负责公司官网全栈开发，以及数据库设计与查询优化。

代表项目



AutoDeploy
智能模型部署与优化平台：自动分析模型、选择优化路径（TensorRT、ONNX、量化、剪枝），并部署到 GPU、FPGA 或 NPU。
ParT 加速 10.4× · ParticleNet 加速 6.6×



投机解码加速
在 vLLM 中实践 DFlash、DSpark 与 MTP 投机解码；训练三层 DFlash 草稿模型并研究提议长度权衡。
解码速度最高提升 3.03×



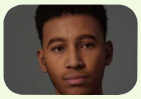
FPGA 与 GPU 加速
基于 HLS、hls4ml 与 Vitis AI 将神经网络部署到 Xilinx FPGA（含 Alveo），并针对 NVIDIA GPU 与昇腾 NPU 优化。
GPU · FPGA · NPU



知识图谱与图神经网络
构建 AutoDeploy 背后的 Neo4j 知识图谱，关联模型、优化技术、工具与硬件；使用 HGT 和 TGN 开展图学习。
Neo4j · HGT · TGN

Qwen3.8

个人 24/7 智能助手
基于 Qwen3.8-27B 的全天候个人助手：使用 llama.cpp 本地部署，由 Hermes Agent 负责工具调用。
个人项目 · 进行中



虚幻引擎 5 与 MetaHuman
场景构建、交互场景与数字人设计；另创作 AI 生成音乐视频。
创意爱好

发表论文

2026 **Draft-budget trade-offs in block-parallel speculative decoding: an empirical study.** Mustofa, Cheng. 已投稿 IEEE CSCWD 2027

2026 **A knowledge-driven framework for HEP model deployment on heterogeneous hardware.** Mustofa, Cheng. *Radiation Detection Technology and Methods*. doi ↗

2026 **MCG: A multi-data-center content gateway for topology-hiding and secure WAN storage access.** Wei et al. *29th IEEE CSCWD 2026*, 2738–2743. doi ↗

2025 **Enhancing GRB detection: Bayesian optimization of triggerless data analysis for LHAASO-WCDA.** Mustofa, Cheng, Yao. *EPJ Web of Conferences* 337. doi ↗

2024 **Fast lossless image compression for synchrotron radiation facility using deep learning.** Minxing et al. *Radiation Detection Technology and Methods* 8(4). doi ↗

2023 **SECHA: A smart energy-efficient, cost-effective home automation system for developing countries.** Mustofa et al. *J. Computer Networks and Communications*. doi ↗

教育背景

博士 · 计算机应用技术
中国科学院大学 / 高能物理研究所 · 2026 至今

工学硕士 · 计算机应用技术
中国科学院大学 / 高能物理研究所 · 2023 – 2026

学士 · 微电子科学与工程
扬州大学 · 2019 – 2023

专业技能

大模型推理与服务
vLLM、llama.cpp、投机解码（DFlash、DSpark、MTP）、CUDA Graph

模型优化
TensorRT、ONNX、量化（PTQ、QAT）、剪枝、hls4ml、Vitis AI

深度学习
PyTorch、Hugging Face、TensorFlow、图神经网络（HGT、TGN）、RL

编程与基础设施
Python、C++、CUDA、Linux、Docker、Git、CI/CD、Neo4j

硬件平台
NVIDIA GPU、Xilinx FPGA、华为昇腾 NPU

语言能力
英语、阿姆哈拉语、汉语（HSK 四级）

荣誉奖项

2026 中国政府奖学金（CSC）
2026 高能物理研究所第 25 届所长奖 · 优秀毕业设计
2023 ANSO 青年人才奖学金
2021 扬杰"优秀学生"奖学金

研究兴趣

模型部署与加速 · 高效大模型推理 · RL · 世界模型 · 自主智能体

兴趣爱好

排球、羽毛球、游泳、台球、健身；托特纳姆热刺球迷。

添加我的微信
微信号：hafizabc77